Faculté
des **sciences économiques** et de **gestion**
Université de Strasbourg

Sentiment Analysis with Machine Learning

BADOUCH Mohamed
ORTEGA Esteban
SOW Assane
ROUSSAUX Claude

Analyse des Sentiments

- Chercher des outils automatiques en vue d'extraire et recueillir des informations dites subjectives en textes de langage naturel.
- Classification d'un texte selon une connotation positive, négative ou neutre.

"Lorem ipsum dolor sit amet, consectetur adipiscing elit, sed do eiusmod tempor incididunt ut labore et dolore magna aliqua. Ut enim ad minim veniam, quis nostrud exercitation ullamco laboris nisi ut aliquip ex ea commodo consequat."

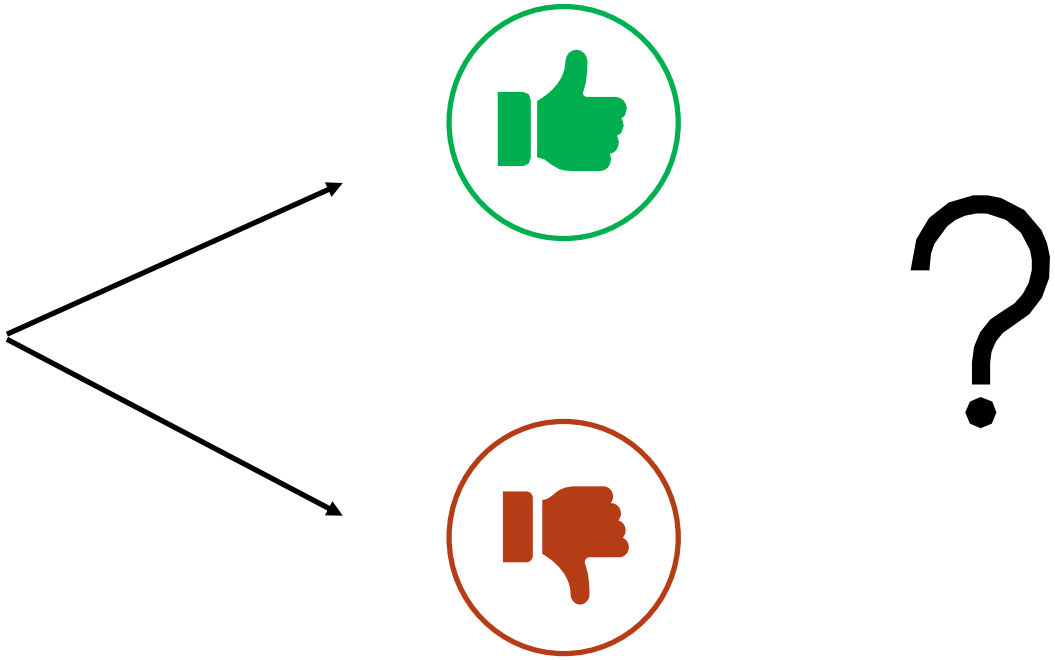

Objectifs

- Estimation d'un modèle de classification en Machine Learning (XGBoost).
- Déploiement du modèle estimé dans une application web.
- Utilisation d'une structure Cloud Computing (Amazon Web Services – AWS).

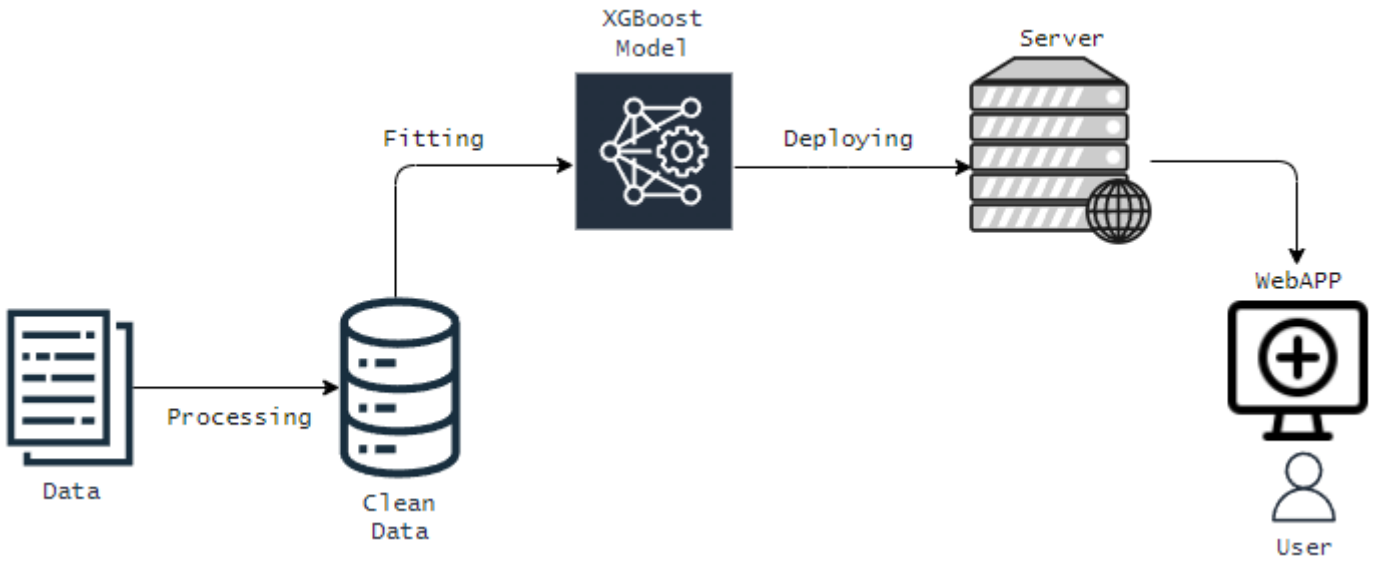

Les données

- Tweets classifiés comme offensifs si contenu de violence sexuel ou racisme.
- Base de donnés déséquilibré (plus des tweets normaux).
- Exploration de texte avec WordClouds.

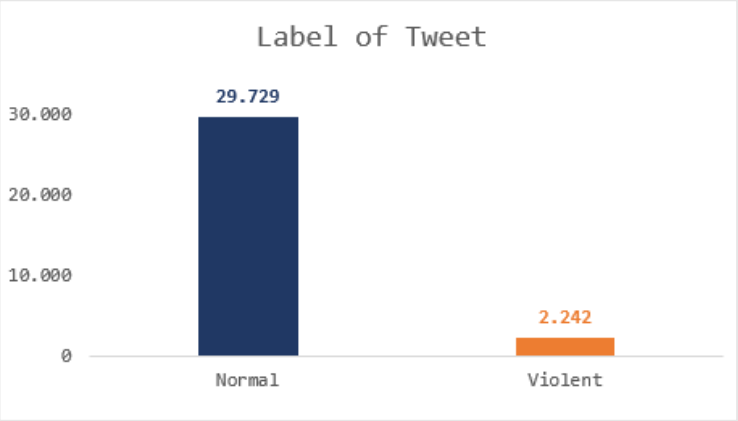

Nuages des mots.

Tweets normales.

Tweets offensifs.

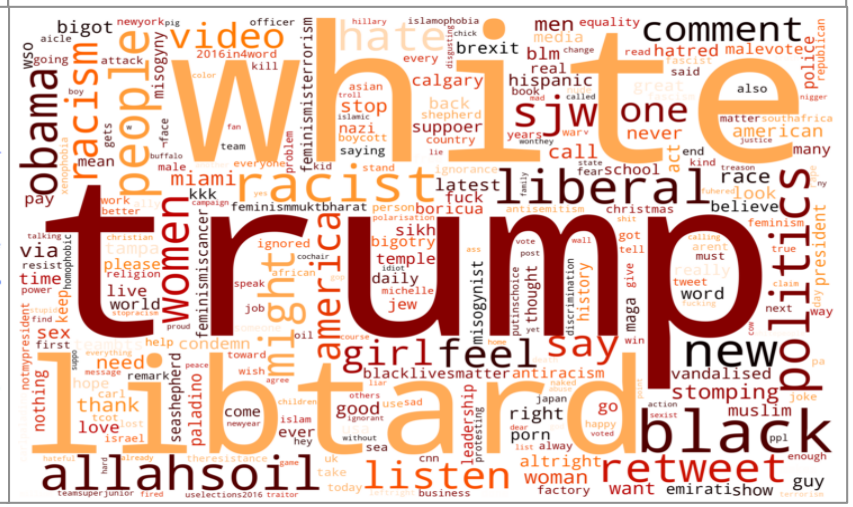
white
trump
libtard
allahsoil
black
retweet
listen
politics
liberal
racist
people
obama
america
women
might
feel
girl
sjw
one
new
say
comment
video
hate
racism
bigot
men
media
blm
hispanic
calgary
stop
back
suppoer
nazi
boycott
country
shepherd
lie
saying
mean
team
feminismisterrorism
misogyny
miami
kkk
feminismmuktbharat
boricua
latest
fuck
sikh
bigotry
temple
daily
michelle
jew
misogynist
thought
discrimination
history
maga
give
tell
must
word
tweet
way
next
win
vandalised
stomping
muslim
japan
right
go
porn
altright
woman
factory
want
emiratishow
guy
enough
sexist
action
happy
voted
dear
list
always
ppl
leadership
protesting
business
cnn
today
sad
use
others
ignorant
sea
take
hey
uk
islam
ever
love
israel
lost
carl
good
seashepherd
paladino
condemn
sex
first
need
remark
hope
nothing
go
notmypresident
president
feminism
look
race
school
fear
state
kind
treason
justice
fuhrer
believe
christmas
antisemitism
polarisation
person
boricua
fuck
latest
feminismmuktbharat
kkk
miami
call
never
one
american
many
matter
southafrica
republican
police
nigger
also
great
boy
book
called
mad
wary
years
wonthey
fan
team
feminismisterrorism
misogyny
face
problem
kid
stand
ignorance
male
everyone
buffalo
gets
bg
boycott
country
shepherd
lie
saying
mean

Préparation des donnés

- Transformer le texte en matrices numériques (Vectorisation).
- Équilibrage des données par échantillonnage aléatoire.

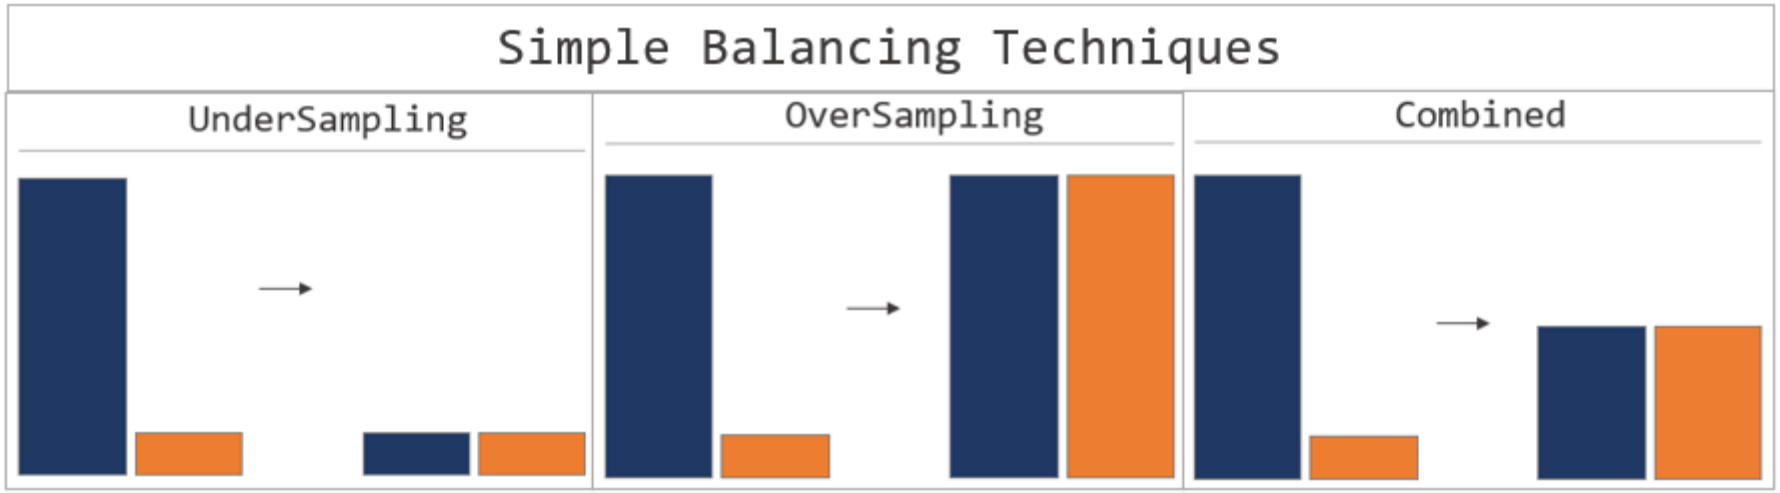

Estimation du modèle

- Modèle eXtreme Gradient Boosting (XGBoost). Méthode basé sur l'estimation consécutive des arbres de décision.
- Maximisation du « Recall », la capacité de trouver les tweets que sont offensifs. Haute sensibilité du modèle.

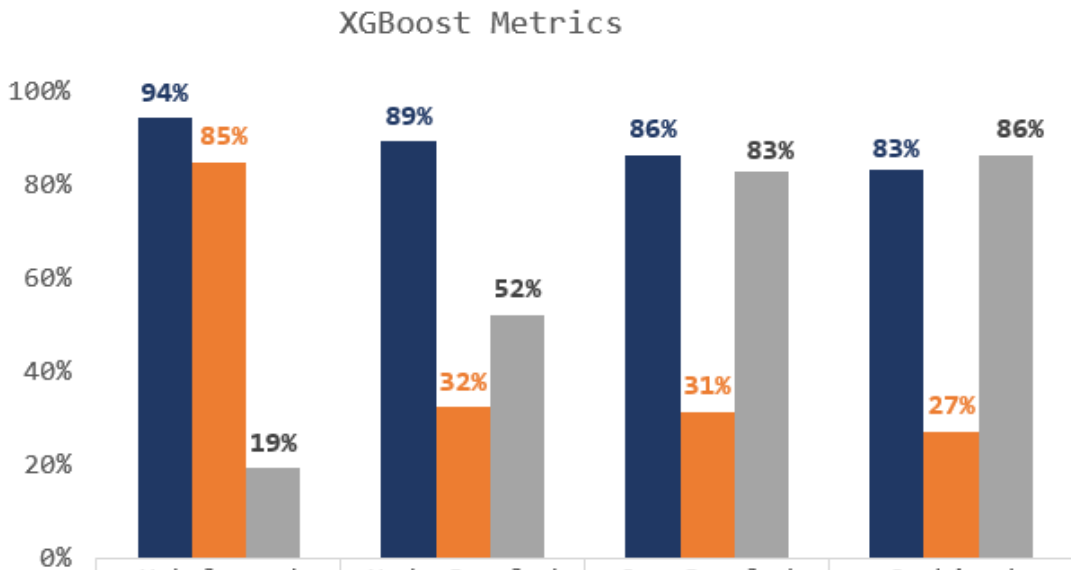

	Unbalanced	UnderSampled	OverSampled	Combined
Accuracy	94%	89%	86%	83%
Precision	85%	32%	31%	27%
Recall	19%	52%	83%	86%

Déploiement - exemples

True normal

Tweet:

I have started the Harry Potter series for the first time ever. And have read maybe the first 3 chapters of the first book so yea. Will be tweeting my opinions. 🤷‍♀️

Submit

Your tweet was normal!

False normal

Tweet:

I feel bad for Disney y'all. bc of the libtard army forcing their views on EVERYTHING we watch...Disney HAS to have gay characters. Disney HAS to have nonbinary characters. its ridiculous! like..let Disney be for the KIDS.

Submit

Your tweet was normal!

False Offensif

Tweet:

Mr. Twitter himself is back. A wrong has been corrected. They tried to silence an important man. We say no sir he will not be silenced Donald Trump President 2024 is back! And he will be back very soon 2024.

Submit

Your tweet was Violent!

True Offensif

Tweet:

We stand with Biden. If WE have to get drafted for war WE will do it

Submit

Your tweet was Violent!

Conclusions

- Un modèle XGBoost est développé et peut identifier 86% des tweets violents qu'il analyse.
- La classification dépend des critères initiaux de la base de données. Par conséquent, ce type de modèle peut être utilisé dans différents domaines.
- Les extensions peuvent inclure différentes méthodes de préparation et d'estimation des données, ainsi qu'un système de retour d'information et d'amélioration continue du modèle.

Faculté
des **sciences économiques** et de **gestion**
Université de Strasbourg

Sentiment Analysis with Machine Learning

BADOUCH Mohamed
ORTEGA Esteban
SOW Assane
ROUSSAUX Claude